

✓ Análisis exploratorio de ventas y comportamiento de clientes

Estudiante: KELY PACHECO

Módulo: Friendly SQL & Python para Analytics

Diploma: Diploma Data Analyst

Objetivo

Analizar el comportamiento de las ventas según producto, categoría, segmento, región y canal, identificando patrones de facturación, descuentos y margen que permitan obtener información útil para la gestión comercial.

Contexto

FerreMarket Perú es una empresa dedicada a la comercialización de productos de ferretería y construcción a través de diferentes canales de venta.

```
!pip -q install duckdb plotly
```

```
import pandas as pd
import numpy as np
import duckdb
import plotly.express as px
from IPython.display import display

pd.set_option("display.max_columns", None)
```

```
df = pd.read_csv(
    "dataset_ventas.csv",
    parse_dates=["Fecha"]
)

print("Dataset cargado correctamente")
```

Dataset cargado correctamente

```
print("Filas:", df.shape[0])
print("Columnas:", df.shape[1])
df.head()
df.tail()
df.info()
print(df.columns.tolist())
```

```
Filas: 3000
Columnas: 14
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3000 entries, 0 to 2999
Data columns (total 14 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   VentaID               3000 non-null   object
 1   Fecha                 3000 non-null   datetime64[ns]
 2   ClienteID             3000 non-null   object
 3   Segmento              3000 non-null   object
 4   Producto              3000 non-null   object
 5   Categoria              3000 non-null   object
 6   Region                3000 non-null   object
 7   Canal                 3000 non-null   object
 8   Cantidad               3000 non-null   int64
 9   PrecioUnitario         3000 non-null   int64
10   Descuento              3000 non-null   float64
11   VentaNeta              3000 non-null   float64
12   Margen                 3000 non-null   float64
13   MedioPago              3000 non-null   object
dtypes: datetime64[ns](1), float64(3), int64(2), object(8)
memory usage: 328.3+ KB
['VentaID', 'Fecha', 'ClienteID', 'Segmento', 'Producto', 'Categoria', 'Region', 'Canal', 'Cantidad', 'PrecioUnitario', 'Des
```

```
calidad = pd.DataFrame({
    "Nulos": df.isna().sum(),
    "Porcentaje": (df.isna().mean() * 100).round(2)
})

display(calidad)
```

	Nulos	Porcentaje
VentaID	0	0.0
Fecha	0	0.0
ClienteID	0	0.0
Segmento	0	0.0
Producto	0	0.0
Categoria	0	0.0
Region	0	0.0
Canal	0	0.0
Cantidad	0	0.0
PrecioUnitario	0	0.0
Descuento	0	0.0
VentaNeta	0	0.0
Margen	0	0.0
MedioPago	0	0.0

```
print(
    "Duplicados:",
    df.duplicated().sum()
)
```

Duplicados: 0

```
for col in df.select_dtypes(include="object").columns:
    print(
        col,
        ":",
        (df[col].astype(str).str.strip() == "").sum()
    )
```

VentaID : 0
ClienteID : 0
Segmento : 0
Producto : 0
Categoria : 0
Region : 0
Canal : 0
MedioPago : 0

```
df.describe()
```

	Fecha	Cantidad	PrecioUnitario	Descuento	VentaNeta	Margen
count	3000	3000.000000	3000.000000	3000.000000	3000.000000	3000.000000
mean	2024-12-30 17:08:09.6000000256	3.956667	54.494667	0.042673	203.588003	47.585730
min	2024-01-01 00:00:00	1.000000	8.000000	0.000000	7.200000	0.930000
25%	2024-07-01 00:00:00	2.000000	18.000000	0.000000	56.000000	11.627500
50%	2024-12-27 00:00:00	4.000000	32.000000	0.050000	108.640000	24.430000
75%	2025-07-07 00:00:00	6.000000	47.750000	0.050000	212.800000	50.367500
max	2025-12-31 00:00:00	7.000000	260.000000	0.100000	1820.000000	582.680000
std	NaN	2.009843	65.734311	0.032237	290.878497	73.391726

```
df.describe(include="object")
```

	VentaID	ClienteID	Segmento	Producto	Categoria	Region	Canal	MedioPago
count	3000	3000	3000	3000	3000	3000	3000	3000
unique	3000	499	3	12	6	6	4	5
top	V03000	C0469	Hogar	Cemento 42.5kg	Herramientas	Arequipa	Tienda	Efectivo
freq	1	18	1351	273	749	535	1279	626

Variables relevantes

Las principales variables consideradas son Fecha, Producto, Categoría, Segmento, Región, Canal, Cantidad, Descuento, VentaNeta y Margen.

Estas variables permiten analizar el comportamiento comercial desde una perspectiva temporal, geográfica, de producto, cliente y rentabilidad.

```
kpis = pd.Series({
    "Total de operaciones": len(df),
    "Ventas netas": df["VentaNeta"].sum(),
    "Ticket promedio": df["VentaNeta"].mean(),
    "Margen total": df["Margen"].sum(),
    "Margen promedio": df["Margen"].mean()
})


display(kpis.to_frame("Valor"))
```

	Valor
Total de operaciones	3000.000000
Ventas netas	610764.010000
Ticket promedio	203.588003
Margen total	142757.190000
Margen promedio	47.585730

```
ventas_categoria = (
    df.groupby("Categoría")["VentaNeta"]
      .sum()
      .reset_index()
      .sort_values("VentaNeta", ascending=False)
)

fig = px.bar(
    ventas_categoria,
    x="Categoría",
    y="VentaNeta",
    text_auto=".2s",
    title="Ventas netas por categoría"
)

fig.show()
```




```
mensual = (
    df.set_index("Fecha")
      .resample("ME")["VentaNeta"]
      .sum()
)
```

```
.reset_index()
)

fig = px.line(
    mensual,
    x="Fecha",
    y="VentaNeta",
    markers=True,
    title="Evolución mensual de ventas"
)

fig.show()
```




```
canal = (
    df.groupby("Canal")["VentaNeta"]
    .sum()
    .reset_index()
)

fig = px.pie(
    canal,
    names="Canal",
    values="VentaNeta",
    hole=0.45,
    title="Participación de ventas por canal"
)


fig.show()
```

Participación de ventas por canal




```
fig = px.histogram(  
    df,  
    x="VentaNeta",  
    nbins=40,  
    title="Distribución de ventas netas"  
)  
  
fig.show()
```

Distribución de ventas netas




```
fig = px.box(  
    df,  
    x="Segmento",  
    y="VentaNeta",  
    title="Distribución de ventas por segmento"  
)  
  
fig.show()
```

Distribución de ventas por segmento



```
fig = px.scatter(
    df,
    x="Descuento",
    y="Margen",
    size="VentaNeta",
    color="Categoria",
    hover_data=[
        "Producto",
        "Canal"
    ],
    title="Relación entre descuento y margen"
)
fig.show()
```

Relación entre descuento y margen



```
q1 = duckdb.query("""
SELECT *
FROM df
LIMIT 10
""").to_df()

display(q1)
```

	VentaID	Fecha	ClienteID	Segmento	Producto	Categoria	Region	Canal	Cantidad	PrecioUnitario	Descuento	VentaNeta
0	V00001	2024-03-03	C0349	Hogar	Martillo profesional	Herramientas	Arequipa	App	6	65	0.03	39
1	V00002	2024-12-31	C0186	Empresa	Brocha 3 pulgadas	Pinturas	Piura	App	6	18	0.00	108
2	V00003	2025-10-11	C0032	Profesional	Foco LED	Electricidad	Junín	App	4	15	0.00	60
3	V00004	2025-05-10	C0390	Hogar	Brocha 3 pulgadas	Pinturas	Cusco	Tienda	3	18	0.10	15.3
4	V00005	2024-09-25	C0484	Hogar	Foco LED	Electricidad	La Libertad	Web	2	15	0.05	28.5
5	V00006	2024-08-29	C0114	Profesional	Alicate	Herramientas	La Libertad	App	2	38	0.00	76
		----			Cable							

```
q2 = duckdb.query("""
SELECT *
FROM df
WHERE Canal = 'Web'
AND VentaNeta > 500
ORDER BY VentaNeta DESC
LIMIT 20
""").to_df()
```

```
display(q2)
```

	VentaID	Fecha	ClienteID	Segmento	Producto	Categoria	Region	Canal	Cantidad	PrecioUnitario	Descuento	VentaNeta
0	V01928	2025-01-15	C0412	Hogar	Taladro inalámbrico	Herramientas	Junín	Web	7	260	0.00	1820
1	V02296	2024-08-30	C0141	Hogar	Taladro inalámbrico	Herramientas	Arequipa	Web	7	260	0.00	1820
2	V00368	2025-04-13	C0376	Profesional	Taladro inalámbrico	Herramientas	Cusco	Web	7	260	0.00	1820
3	V00363	2024-04-14	C0189	Hogar	Taladro inalámbrico	Herramientas	Piura	Web	7	260	0.05	1715
4	V00296	2025-12-12	C0130	Profesional	Taladro inalámbrico	Herramientas	Piura	Web	7	260	0.05	1715
5	V02918	2024-07-30	C0390	Hogar	Taladro inalámbrico	Herramientas	La Libertad	Web	7	260	0.05	1715
6	V02682	2024-12-11	C0238	Hogar	Taladro inalámbrico	Herramientas	Junín	Web	7	260	0.05	1715
7	V00267	2025-06-11	C0430	Empresa	Taladro inalámbrico	Herramientas	Junín	Web	7	260	0.05	1715
8	V01685	2025-12-28	C0313	Profesional	Taladro inalámbrico	Herramientas	La Libertad	Web	6	260	0.00	1560
9	V00329	2025-11-29	C0365	Empresa	Taladro inalámbrico	Herramientas	Junín	Web	6	260	0.00	1560
10	V01682	2025-06-20	C0189	Profesional	Taladro inalámbrico	Herramientas	Cusco	Web	6	260	0.00	1560
11	V02441	2025-04-10	C0469	Empresa	Taladro inalámbrico	Herramientas	Arequipa	Web	6	260	0.03	1512
12	V01452	2024-04-10	C0074	Profesional	Taladro inalámbrico	Herramientas	Cusco	Web	6	260	0.03	1512

```
q3 = duckdb.query("""
SELECT
    Categoria,
    COUNT(*) AS Operaciones,
    SUM(VentaNeta) AS Ventas,
    AVG(Margen) AS MargenPromedio
FROM df
GROUP BY Categoria
""").to_df()

display(q3)
```

	Categoria	Operaciones	Ventas	MargenPromedio
0	Herramientas	749	334223.18	105.251482
1	Pinturas	499	105126.30	48.539479
2	Electricidad	475	49747.32	24.323158
3	Seguridad	500	55459.89	25.748220
4	Plomería	504	32451.16	14.972718
5	Construcción	273	33756.16	28.310513

```
q4 = duckdb.query("""
SELECT
    Region,
    SUM(VentaNeta) AS VentasTotales,
    AVG(VentaNeta) AS TicketPromedio
FROM df
GROUP BY Region
ORDER BY VentasTotales DESC
""").to_df()

display(q4)
```

	Region	VentasTotales	TicketPromedio
0	Junín	112198.12	228.044959
1	La Libertad	110441.43	215.705918
2	Arequipa	102090.19	190.822785
3	Piura	98406.14	203.739420
4	Lima	97161.58	191.262953
5	Cusco	90466.55	192.482021

```
q5 = duckdb.query("""
SELECT
    Canal,
    Segmento,
    COUNT(*) AS Operaciones,
    SUM(VentaNeta) AS Ventas,
    AVG(Descuento) AS DescuentoPromedio,
    AVG(Margen) AS MargenPromedio
FROM df
GROUP BY Canal, Segmento
HAVING SUM(VentaNeta) > 100000
ORDER BY Ventas DESC
""").to_df()

display(q5)
```


	Canal	Segmento	Operaciones	Ventas	DescuentoPromedio	MargenPromedio
0	Tienda	Hogar	577	114306.66	0.041005	46.632912
1	Tienda	Profesional	502	102813.59	0.043904	48.562809

5. Hallazgos

Hallazgo 1 — Categoría con mayores ventas

La categoría **[RESULTADO]** registra las mayores ventas netas, alcanzando **S/ [RESULTADO]**.

Hallazgo 2 — Canal con mayores ventas

El canal **[RESULTADO]** concentra el mayor volumen de ventas netas, con **S/ [RESULTADO]**.

Hallazgo 3 — Región con mayores ventas